

¿Realmente importa?

Semántica de contrafácticos y el valor epistémico de la verdad

OSCAR ABRAHAM OLIVETTI ALVAREZ

Universidad Nacional Autónoma de México

Índice general

Índice general	II
Una breve anécdota	III
Bibliografía	1

Introducción

Una breve anécdota

El doctorado ha sido un largo viaje durante el cuál aprendí mucho. La parte más importante del aprendizaje está relacionado con la filosofía,¹ y la alta calidad del posgrado me permitió profundizar en los temas que me interesaban. Mi pasión en ellos nació durante mi licenciatura. Me fascinaron los temas que vimos en clase de filosofía de la ciencia, en particular, debido a que durante este periodo tuve dos profesores que se dedicaban a la filosofía de la ciencia². Ambos excelentes maestros y filósofos.

Mi atención la dirigí especialmente a los temas de la *explicación científica* y la *naturaleza de la causalidad*. Mis intuiciones —todavía queda un resabio de esto— sugerían que encontrar la causa de un fenómeno es la mejor manera de explicarlo. Por ejemplo, que la mejor explicación de por qué tengo cáncer de pulmón se debe a mis hábitos de fumador, y fumar *es una* causa de cáncer.

Que la causalidad debería ser parte de nuestra teoría de la *explicación científica*, es una intuición que no está muy alejada de algunas teorías clásicas. La motivación más clara para incluir una relación causal en nuestras teorías de la explicación científicas se debe a que la explicación de un fenómeno es *asimétrica*, algo que Sylvain Bromberger hizo notar en su artículo «Why-Questions». Para presentar el argumento de Bromberger, primero quiero describir brevemente lo que Hempel y Oppenheim dijeron en torno a la explicación científica³.

Hempel y Oppenheim en «Studies in the Logic of Explanation», caracterizaron a la explicación científica como un argumento deductivo. Sabemos, por ejemplo, que todos los metales se dilatan cuando se calientan. Si calentamos un pedazo de cobre particular, entonces debería dilatarse. Si esto es verdad, entonces lo que explica por qué este pedazo de cobre se dilata cuando lo caliente es el hecho de que es una instancia particular de un cuantificador universal. Nótese que es crucial la oración cuantificada universalmente. En principio, esta oración debe tener la forma de una *ley general*. Si estas condiciones se cumplen, entonces podemos derivar como caso particular el fenómeno en cuestión.

Sin embargo, Bromberger en «Why-Questions» detecta un problema con esta caracterización de la explicación científica. Bromberger comienza argumentando que hay muchas similitudes entre explicar que este pedazo de cobre

¹ Juro que este breve relato tiene un punto.

² Al menos, lo que en ese momento pensaba que era la filosofía de la ciencia

³ Uso el término para referirme a lo que hacen las personas que se dedican a la investigación en cualquier área del conocimiento, cuando decimos que estas personas *explican* un fenómeno.

se dilata y responder a la pregunta “¿por qué este pedazo de cobre se dilata cuando lo caliente?”, señala, por ejemplo, que

... there are issues in the philosophy of science that warrant an interest in the nature of why-questions. The most obvious of these issues are whether science (or some branch of science or some specific scientific doctrine or some approach) ought to, can, or does provide answers to why-questions, and if so, to which ones. (p. 89)

Hay un fuerte sentido intuitivo en la afirmación de Bromberger. No es exagerado suponer que la investigación científica se dedica a responder respuestas de este tipo⁴: es claro que una explicación suele ser una respuesta a una pregunta *por-qué*. Sin embargo, si la doctrina hemepeliana es correcta, entonces la respuesta a la pregunta “¿por qué la altura del Empire State es de 381 metros?” debería responderse de la siguiente manera: supongamos que hay un punto en quinta avenida que está a x distancia del Empire State. Dadas las leyes de la óptica y el ángulo que forma el rayo de sol desde el punto más alto del edificio hasta el punto x , podemos derivar fácilmente la altura del Empire State.

Este es un argumento deductivo del cual —sustituyendo las variables pertinentes,— podemos adecuadamente concluir la altura del Empire State. Si la doctrina hemepeliana es correcta, entonces esto significa que este argumento explica la altura del Empire State, algo que claramente es incorrecto: nadie diría que el hecho de que el ángulo del sol y la distancia al punto x de Quinta Avenida explica por qué el edificio mide 381 metros. Eso probablemente debería explicarlo un arquitecto o quien sea que haya planeado el edificio.

El problema con lo que Bromberger llama “La doctrina hemepeliana,” es que contraejemplos como este muestran que la teoría es incorrecta. Estos contraejemplos atacan la simetría de la explicación que surge a partir de la doctrina hemepeliana. Pero las explicaciones no son simétricas.

Si lo que señala Bromberger es verdad, entonces las condiciones de Hempel no son suficientes para caracterizar el fenómeno de la explicación científica. Durante este periodo de la filosofía, muchos esfuerzos filosóficos se concentraron en resolver el problema de la asimetría —y algunos otros problemas derivados de la doctrina hemepeliana.— Wesley Salmon, por ejemplo, discute en «Statistical Explanation», cómo podríamos resolver el problema de la asimetría.

Wesley Salmon discute el ejemplo de Bromberger. En particular, Salmon menciona que la asimetría temporal es crucial para explicar la altura del edificio, en la página 72, Salmon dice que

Although the sun, flagpole, and shadow are perhaps commonsensically regarded as simultaneous, a more sophisticated analysis shows that physical processes going on in time are involved. Photons are emitted by the sun, they travel to the vicinity of the flagpole where

⁴Es una cuestión distinta si la investigación científica puede responder a *todas* las preguntas de este tipo.

some are absorbed and some are not, and those which are not go on to illuminate the ground

En breve, la afirmación principal que defiende Salmon es que si una variable hace una diferencia en el resultado esperado, entonces tenemos una explicación del resultado. Salmon reconoce, sin embargo, que su teoría de la explicación científica es sensible al problema de hacer pasar las correlaciones por relaciones de dependencia. En estadística es común el eslogan “correlación no implica causalidad” y el problema que señala el autor es que si sólo caracterizamos a la explicación como estadísticamente relevante, entonces vamos a perder casos claros de explicación científica. Por ejemplo, si tengo un dolor de cabeza debido a que no he tomado agua, y sin darme cuenta me tomo una pastilla del frasco –que resulta que es un dulce–, no puedo afirmar que fue la pastilla la que me quitó el dolor de cabeza. En este caso fue el agua, que es el factor causal relevante.

Para resolver esto, Salmon hace notar que su modelo de explicación puede naturalmente incorporar *explicaciones causales*, que es un requerimiento para resolver el problema de la asimetría de la explicación, Salmon menciona, por ejemplo que

The reason that the explanation of the length of the shadow in terms of the height of the flagpole is acceptable, whereas the “explanation” of the height of the flagpole in terms of the length of the shadow is not acceptable, seems to me to hinge directly upon the fact that there are causal processes with earlier and later temporal stages.

Podemos encontrar en la literatura contemporánea, son destacables las teorías de la explicación científica que incluyen factores causales. Por ejemplo, Potochnik nos dice que “[. . .] I make the case that much of science is profitably understood as the search for causal patterns.” (Potochnik, 2017, p. 24)

Este “espíritu causal” nota incluso en libros de texto. Por ejemplo, cabe notar que en Pearl et al., 2016, los autores inician señalando que la causalidad *debería* ser empleada en nuestras explicaciones estadísticas, en la página 1, los autores comentan

We study causation because we need to make sense of data, to guide actions and policies, and to learn from our success and failures. We need to estimate the effect of smoking on lung cancer, of education on salaries, of carbon emissions on the climate.

Un poco más adelante, nos dicen que

When approached rigorously, causation is not merely an aspect of statistics; it is an addition to statistics, an enrichment that allows statistics to uncover workings of the world that traditional methods alone cannot.

Esto es sólo una muestra del vínculo que hay entre causalidad y explicación. Ahora bien, dentro de las teorías de la explicación que involucran un componente causal, ha emergido la teoría *manipulabilista* de la explicación causal. Woodward desarrolló dicha teoría y actualmente es uno de sus mayores exponentes.

Hablando particularmente de las teorías *manipulabilistas* de la causalidad (Woodward, 2023), Potochnik afirma que son dichas teorías las que mejor parecen adecuarse a cómo de hecho se trabaja en investigación científica. Esto es importante, ya que como filósofos de la ciencia, nuestro análisis debería estar informado por cómo de hecho se trabaja en investigación científica.⁵

Si bien no hay un consenso universal sobre la relevancia de la causalidad en el fenómeno de la explicación científica, con la discusión anterior quiero sugerir que la causalidad es una característica fundamental del proceso de explicación científica. Dicho esto, quiero presentar brevemente en qué consiste una teoría manipulabilista de la causalidad.

Brevemente, las teorías *manipulabilistas*⁶ afirman que dadas dos variables A y B , decimos que A *causa* B si al intervenir (manipular) la variable A , la variable B cambia en consecuencia. Esto, por supuesto, sólo es una parte de la historia de las teorías *manipulabilistas*. Supongamos que el fenómeno a analizar es estable, es decir., que cualquier cambio de valor en la variable A , implica un cambio proporcional en B . Si hay una función bien definida sobre un conjunto, la tarea es ligeramente sencilla. Pensemos, por ejemplo, en una función cualquiera de una variable. Digamos que la función está definida de la siguiente manera $f(x) = 2x$, donde $x \in N$. Esto significa que si la función toma el 3 como valor de entrada, el valor de salida será 6. Supongamos que estos son los valores de una medida de fuerza y que la relación es la siguiente: Si la fuerza A es de 1 unidad, entonces la distancia B trasladada de un proyectil es de 2.⁷

Digamos entonces que aplicar 3 medidas de fuerza, producen *cuatro metros* de distancia de un proyectil. Supongamos además que esta función es *independiente* de cualquier fuerza externa, por ejemplo, la resistencia del medio (en este caso el aire) –insisto en que esto es sólo un caso para ejemplificar.

Un teórico de la aproximación causal intervencionista, diría que esto significa que la fuerza impresa en el proyectil, *causa* que el proyectil alcance más distancia. Además es posible que la función definida anteriormente no sea correcta para algunos de los valores de A , por ejemplo, si imprimo una fuerza de $1 * 10^{-7}$ unidades, probablemente el proyectil no se traslade $2 * 10^{-7}$ unidades.

El ejemplo anterior sirve para describir algunas de las características de la teoría *manipulabilista*. Que la función describa correctamente el comportamiento del proyectil, *independiente* de otra fuerza, quiere decir que la fuerza impresa en el proyectil es la única variable que afecta la distancia del mismo.

Que la *intervención* en la fuerza impresa cause que el proyectil llegue a mas distancia –*independiente* de cualquier otra fuerza,– significa que en la medida de los posible hemos decidido dejar variables (como la resistencia del aire) exógenas: sabemos que pueden afectar el comportamiento, pero nos concentramos en explicar la distancia en función de la fuerza. Si además podemos excluir todas las variables, excepto la fuerza, entonces es posible hacer una interven-

⁵ Abrams 2023, por ejemplo, discute esto en el primer capítulo de su libro.

⁶ La siguiente caracterización está basada en Woodward, 2000, 2004; Ross y Woodward, 2023; Woodward, 2023

⁷ Por supuesto esto es púramente ficticio, se trata sólo de un ejemplo ilustrativo, el punto es que la función de distancia es proporcional a la medida de fuerza

ción “quirúrgica” y que sólo haya ciertos valores que describen correctamente el comportamiento del proyectil, significa que es *invariante* bajo un rango de intervenciones. En esto, a grandes rasgos, consiste una teoría *manipulabilista* de la causalidad.

Por supuesto, hay otras características que integran la teoría *manipulabilista* de la causalidad. Quizás la más controversial de ellas es que la teoría hace uso de condicionales *contrafácticos*. Los condicionales *contrafácticos* son aquellos condicionales que evaluamos bajo el supuesto de que algo no sucede, pero que nos obligan a preguntarnos que pasaría si se cumplieran ciertas condiciones particulares. Dicho de otro modo, nos preguntamos cómo sería el mundo si, por ejemplo, México no hubiera sido conquistado por los españoles.

Parece más que natural implementar estos condicionales en la teoría intervencionista de la causalidad. Porque dado que las variables pueden ser tanto discretas como continuas, podríamos analizar preguntas del tipo “¿qué hubiera sucedido si *A* hubiera tomado un valor distinto al que tomó?”. Si la función está bien definida, como en mi ejemplo, entonces es relativamente sencillo determinar valores de distancia para diferentes valores de fuerza⁸

Me parece que si tomamos en serio el trabajo que realizan las personas cuando hacen investigación, es claro que el uso de estas herramientas juega un papel en su trabajo y, de manera particular, los modelos estadísticos mencionan condicionales *contrafácticos* como parte de sus análisis. Entre dichos métodos, resalta la *inferencia causal*, que es un método estadístico que se utiliza para erivar conclusiones causales a partir de agregación de datos e inferencia estadística. Estos métodos sirven, sobre todo, cuando utilizamos modelos estadísticos para justificar hipótesis causales (Pearl et al., 2016; Pearl & Mackenzie, 2018).

Un ejemplo de este tipo de métodos —en el cuál se usan métodos de inferencia causal—, es en las *Pruebas Controladas Aleatorizadas* (RCT, por sus siglas en inglés), donde típicamente, los investigadores interesados en saber cuál es la efectividad de un medicamento, intervienen en una de las variables —dándole un placebo a un grupo de control, mientras que otro grupo recibe el medicamento a testar. Asumiendo que no hay sesgos en la muestra, si el grupo de prueba responde al medicamento, entonces, en principio, seremos capaces de detectar si el medicamento hace una aportación causal. En corto: que podemos pensar que el grupo de control funciona como una especie de imagen de lo que *habría* pasado de no haber tomado los medicamentos.

Hasta este momento de la exposición, estoy hablando de cómo los *condicionales contrafácticos* como un elemento de que es parte de la *investigación científica*. Lo que me interesa de estos ejemplos es resaltar el hecho de que *las inferencias causales*, que modelan fenómenos usando *contrafácticos*, son parte del trabajo usual de los investigadores. Algo que queda reflejado en (Pearl et al., 2016), en (Pearl & Mackenzie, 2018) y especialmente en (Llaudet & Imai, 2023).

Sin embargo, el hecho de que los contrafácticos sean parte de estos métodos usados en investigación, no significa que todos los problemas están resueltos. En particular, me importa señalar un problema que ha recibido el nombre de “el problema fundamental de la inferencia causal.” Brevemente, el problema

⁸ En investigación, se suele mencionar el uso de condicionales *contrafácticos*, principalmente en inferencias causales, por ejemplo Pearl et al., 2016; Pearl y Mackenzie, 2018.

consiste en que no es posible saber el valor de verdad de un *contrafáctico* a nivel del individuo. Por ejemplo, supongamos que queremos saber si los estudiantes que leen un libro al año, tienen un mejor desempeño académico que aquellos alumnos que leen menos de un libro al año. Supongamos, aún más, que hemos diseñado una prueba aleatoria randomizada y que hemos aislado existosamente a los alumnos que leen más de un libro al año. Si nos preguntamos qué hubiera sucedido si los alumnos no leyeron al menos un libro al año. Para responder a la pregunta “¿qué habría pasado si ...?” tenemos que ver cómo fue el desempeño del grupo de control, es decir, aquel que leyó menos de un libro al año. La única información que tenemos, entonces, será el agregado estadístico de los alumnos que leyeron menos de un libro al año. Sin embargo, esto significa que nunca seremos capaces de observar, digamos, que hubiera sido de Ana Sandoval si hubiera leído menos de un libro al año. Esto significa que hemos perdido una explicación causal de por qué Ana Sandoval tuvo un mejor desempeño que Jorge Monreal. Simplemente porque no podemos observar que habría sido de Ana si hubiera leído menos de un libro al año, o bien, qué hubiera sido de Jorge si hubiera leído al menos un libro al año.

Esto implica un problema acerca del significado o valor de verdad de contrafácticos que tienen como argumento un nombre propio: podemos hacer inferencias de cómo el grupo de prueba y el grupo de control difieren, y si esto implica una relación causal entre *leer* y *desempeño académico*. Resta señalar exactamente cuál es el papel que juegan. Además, quienes usan este tipo de métodos en su investigación tienen presente que con este método hemos perdido causas particulares *tokens* que toman eventos como relata. Por ejemplo, de la forma

Por el momento, no voy a entrar en detalles sobre qué son y cuál es la naturaleza los condicionales contrafácticos, eso es algo que planeo hacer en un capítulo posterior. Para fines de exposición, sólo basta mencionar que los condicionales contrafácticos encuentran su aplicación en estos contextos para, digamos “crear” un evento alterno (Si asumimos que no hay sesgos en los grupos de control y de prueba, y que hemos eliminado causas comunes dentro de nuestro análisis), en principio, seremos capaces de derivar una conclusión causal Pearl et al., 2016; Otsuka, 2023.

No voy a hacer una defensa de la teoría *manipulabilista* de la causalidad. Eso lo hice en mi proyecto de maestría—sea cual sea el éxito que haya tenido esta defensa—, en particular, intenté elucidar cómo una teoría manipulabilista lidia con explicaciones causales en biología evolutiva. Mi proyecto actual nace de preocupaciones que restaron de ese proyecto. En particular, si es verdad que en la investigación científica se hace uso de condicionales contrafácticos, entonces vale la pena preguntarse (i) *¿cómo sabemos qué condicionales contrafácticos son “verdaderos”?*

Hay mucho que desempaquetar en la pregunta (i). Primero, la pregunta es parte de un condicional, esto es intencional. De este condicional quiero extraer la conclusión de que de hecho vale la pena esa pregunta. Presentar este

condicional es parte de la motivación del proyecto. Hasta ahora he mencionado brevemente las aplicaciones que hacen mención de contrafácticos, lo cual ofrece una motivación para preguntar (i). Supongamos por un momento que dichos condicionales de hecho son parte de la investigación –digamos que son parte de los métodos que usan los investigadores. El capítulo 1 lidia con cómo estos condicionales son y 2 lidian con No sólo eso, sino que responder a (i) equivale a explicar por qué la conclusión tiene sentido, de acuerdo al marco teórico en el que se desarrollará.

Mi proyecto se concentra en resolver por qué *la verdad* juega un papel importante en la investigación científica y luego en cómo *justificar* qué condicionales contrafácticos cumplen este criterio.

Mi proyecto se concentrará Parece que queda claro que herramientas estadísticas, en el contexto de las inferencias causales, echan mano de *condicionales contrafácticos*. Además, son estos condicionales, los que nos permiten trazar relaciones causales según la teoría *manipulabilista*. Una motivación que se ha mencionado en la literatura para introducir métodos que nos permitan trazar relaciones causales es la llamada “paradoja de Simpson.” Esto no es estrictamente una paradoja, pero aparece cuando los datos se comportan de manera poco intuitiva (Hájek & Hitchcock, 2016, p. 13). Algunos autores han señalado que la solución radica en ser capaces de ofrecer un método para obtener relaciones causales a partir de datos estadísticos.

Este tema –el de la explicación causal– está fuertemente vinculado con el uso de herramientas y *modelos* estadísticos en investigación. Mi propósito es hacer claro cómo funcionan dichos modelos y qué herramientas nos sirven para justificar que en efecto dos variables están causalmente relacionadas. Esto es importante, porque en muchos casos se suele decir que los *modelos* usados en investigación, sea cual sea su uso, son “falsos”

Se suele señalar que hay un sentido en el cuál los modelos son “falsos”, sentido que suele expresar como “[...] models typically only hold *approximately*, in some ranges of circumstances, and they liberally employ idealizations to accomplish this *partial* fit.” (Potochnik, 2017, p. 18, énfasis agregado)

Potochnik también afirma que buena parte de la investigación se centra en ofrecer explicaciones causales y, más aún, afirma que una buena manera de lidiar con explicaciones causales en investigación científica es adoptando una teoría causal *manipulabilista*. Los argumentos de Potochnik que vinculan a la práctica de investigación con las teorías *manipulabilistas*, dejan claro que hay una genuina preocupación sobre cómo de hecho se realiza investigación.

Potochnik también defiende que el uso de modelos en investigación –y cualquier supuesto que imponga ciertas condiciones en el modelo– surge de la necesidad de que seres con capacidades cognitivas limitadas queremos representar fenómenos naturales para aislar los factores causales bajo escrutinio. Es importante poner énfasis en esto porque implica que los modelos *son generados* con ciertos objetivos en mente, o como ella misma señala “[...] the nature of these idealizations is relative to the aim of research, as is most clearly demonstra-

ted by the different idealizations involved in the various approaches to human aggression research.”

Mi investigación actual lidia con la afirmación de que los modelos son falsos. Este no es un problema grave si la “verdad” no es una parte central de la investigación científica (en cualquier disciplina). Pero si la investigación se propone *justificar* hipótesis para obtener *conocimiento* de relaciones causales reales, entonces tenemos un problema. ¿Cómo los modelos, que no representan adecuadamente el fenómeno, pueden dar como resultado conocimiento? Si suponemos que el conocimiento es fáctico, entonces entramos en problemas.

El problema, me parece, radica en cómo representamos adecuadamente un fenómeno. Debo aclarar también cómo es que funciona la representación científica y cómo la adecuación parcial de modelos que usan contara fácticos, implica fenómenos fácticos.

Mi hipótesis es que cierta forma de verdad debe estar involucrada en nuestra definición de *conocimiento*, si es que queremos que las intervenciones en un sistema sean de alguna utilidad. Por ejemplo, si el aumento del salario mínimo causa un aumento en el desempleo y qué condiciones juegan un papel causal en dicha relación.

Regresando a la anécdota, el hecho de que estos dos profesores buenos trabajaran filosofía de la ciencia –al menos lo que en ese momento creía que era la filosofía de la ciencia– sesgó mis intereses a lo que hasta ahora ha sido mi trabajo. La influencia de estos dos profesores me hizo tomar la decisión de entrar al posgrado en Filosofía de la Ciencia.

En las clases de maestría hubo profesores excelentes. Mucho de lo que aprendí en estos cursos me sirvió para enmarcar de diferente manera las preguntas que me preocupaban, lo cuál me permitió entender –mejor, me parece– la naturaleza de la investigación científica. En particular quería responder preguntas sobre la epistemología de la ciencia, preguntas del tipo: “¿qué estamos justificados a creer?”, “¿cuándo podemos afirmar que una hipótesis ha sido corroborada?”, “¿es la explicación o comprensión más básica que el conocimiento?”, etc. Preguntas que surgen a partir de mi interés por la explicación causal.

Ahondar en estas preguntas y tratar de responderlas es una tarea más que complicada. Muchos de los obstáculos se deben a que la práctica científica es más caótica y heterogénea de lo que parece en un principio. Incluso si nos concentramos en el uso de herramientas estadísticas o herramientas que echan mano de la teoría de la probabilidad, en casi todos los casos, ciertas propiedades del *fenómeno en cuestión* son idealizadas o ignoradas para hacer que el modelo estadístico sea de utilidad.

Esta representación parcial del fenómeno se debe a que en muchos casos buscamos destacar algunas propiedades particulares del fenómeno, sin que todas las variables estén representadas en el modelo. Que no involucremos todas y cada una de las variables que afectan el fenómeno es un reflejo de nuestra limitada capacidad cognitiva. A lo largo de su escrito, Potochnik nos recuerda que los modelos diseñados en la investigación científica tienen un propósito

particular. Son usados para destacar algunas propiedades particulares, especialmente, especialmente si lo que nos interesa son las relaciones causales. Que simplifiquemos de cierta manera el modelo se debe a que los investigadores intentan resaltar las características de un fenómeno en un momento particular.

Potochnik no es la única que ha señalado esto, Abrams (2023, p.24), por ejemplo, nos recuerda que “So-called infinite-population models are simply models that have no role for drift. Biologists do often say things about evolution in infinite populations, and these claims are usually correct: the role of this terminology *in practice* implies that it should not be understood literally.” (énfasis agregado)

A pesar de que los modelos no son completamente adecuados, –en el sentido en el que no representan totalmente el fenómeno en cuestión,– son ampliamente utilizados en la investigación científica. Si estas herramientas son usadas ampliamente, entonces como filósofos de la ciencia hay que ofrecer un análisis de cómo exactamente los modelos sirven para justificar hipótesis si parten de supuestos obviamente falsos.

Me parece que buena parte del problema está relacionado con determinar cuál es el papel que juega la *representación adecuada* y la *verdad* en la investigación científica. Para motivar mi afirmación anterior, quiero dar un repaso por un periodo de la filosofía de la ciencia, un periodo en el cuál –suele decirse– la *verdad* jugaba un papel central en los análisis filosóficos de la ciencia: me refiero al periodo en el que los miembros del Círculo de Vienna estuvieron vivos. Este repaso sirve para motivar la afirmación de que la *verdad* juega un papel en la investigación científica –por el momento no asumiré cuál es ese papel,– mientras que esto es al mismo tiempo compatible con la “representación parcial” que hacen los modelos de un fenómeno.

Para comenzar este repaso, debo señalar que en la maestría aprendí nuevas metodologías de investigación, además de diferentes maneras de plantear y entender las preguntas que me preocupaban. Pero lo más valioso que aprendí fue la importancia que tiene la historia de la ciencia en la filosofía de la ciencia. Me voy a permitir hacer una breve caracterización, exageradamente general, de dos posturas en historia de la ciencia.

Bibliografía

- Hempel, C. G., & Oppenheim, P. (1948). Studies in the Logic of Explanation. *Philosophy of Science*, 15(2), 135-175. <https://doi.org/10.1086/286983>
- Bromberger, S. (1966). Why-Questions. En R. G. Colodny (Ed.), *Mind and Cosmos: Essays in Contemporary Science and Philosophy* (pp. 86-111). University of Pittsburgh Press.
- Salmon, W. (1970). Statistical Explanation. En *The Nature and Function of Scientific Theories*.
- Woodward, J. (2000). Explanation and Invariance in the Special Sciences. *British Journal for the Philosophy of Science*, 51(2), 197-254. <https://doi.org/10.1093/bjps/51.2.197>
- Woodward, J. (2004, enero). *Making Things Happen: A Theory of Causal Explanation*. Oxford University Press. <https://doi.org/10.1093/0195155270.001.0001>
- Hájek, A., & Hitchcock, C. (Eds.). (2016). *The Oxford Handbook of Probability and Philosophy*. Oxford University Press.
- Pearl, J., Glymour, M., & Jewell, N. (2016). *Causal Inference in Statistics: A Primer*. Wiley. <https://books.google.com.mx/books?id=L3G-CgAAQBAJ>
- Potochnik, A. (2017). *Idealization and the Aims of Science*. University of Chicago Press.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books. <https://books.google.com.mx/books?id=EmY8DwAAQBAJ>
- Abrams, M. (2023). *Evolution and the Machinery of Chance: Philosophy, Probability, and Scientific Practice in Biology*. University of Chicago Press. <https://books.google.com.mx/books?id=piO2EAAAQBAJ>
- Llaudet, E., & Imai, K. (2023). *Data Analysis for Social Science: A Friendly and Practical Introduction* (1.^a ed.). Princeton University Press.
- Otsuka, J. (2023). *Thinking about Statistics: The Philosophical Foundations*. Routledge, Taylor & Francis Group. <https://books.google.com.mx/books?id=JPz4zgEACAAJ>
- Ross, L., & Woodward, J. (2023). Causal Approaches to Scientific Explanation. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Spring 2023). Metaphysics Research Lab, Stanford University.

Woodward, J. (2023). Causation and Manipulability. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Summer 2023). Metaphysics Research Lab, Stanford University.