

Introducción

Una breve anécdota

Parte I

El Doctorado ha sido un proceso extenso durante el cual he aprendido muchísimo. La parte más sustanciosa de lo que he aprendido está relacionado con la filosofía, en particular filosofía de la ciencia ¹. La alta calidad del posgrado me ha permitido profundizar en los temas que me interesaban, interés que me motivó a entrar a este doctorado.

La fascinación que tengo por los temas en filosofía de la ciencia nació durante mi licenciatura, porque durante este periodo tomé cursos con dos profesores que se dedicaban al área². Ambos excelentes maestros y filósofos.

Durante este periodo de mi formación (licenciatura) mi atención estuvo enfocada a los temas de la *explicación científica* y la *naturaleza de la causalidad*. Mis intuiciones—todavía queda un resabio de esto—sugerían que señalar cuál es la causa de un fenómeno es la mejor manera que tenemos de explicarlo³. Por ejemplo, parece claro que la mejor explicación de por qué tengo cáncer de pulmón se debe a mis hábitos de fumador, y fumar *es una causa* de cáncer.

Que la causalidad sea parte de nuestra teoría de la *explicación científica*, es una intuición que no está alejada de algunas teorías de la explicación clásicas discutidas en filosofía de la ciencia. Me parece además que la motivación más clara para incluir una relación causal en nuestras teorías de la explicación científica, se debe a que nos parece necesario que la explicación de un fenómeno es *asimétrica* : que haya explotado el alimentador de electricidad, explica por qué mi computadora se apagó y perdí toda mi tesis. Pero claramente perder mi tesis no explica por qué explotó el alimentador eléctrico. Llamemos a esto *condición de asimetría de la explicación* [CA]. «Statistical Explanation»

¹ Juro que este breve relato tiene un punto.

² Al menos, lo que en ese momento pensaba que era la filosofía de la ciencia. Si les pregunto, estoy seguro de que su respuesta sería que no se dedican a la filosofía de la ciencia.

³ Estoy usando de manera coloquial el término. Uso el término para hablar de aquello que hacen las personas en cualquier ámbito de la vida en el que se requiere ofrecer una explicación. Por ejemplo Que la carne se echó a perder porque el refrigerador dejó de funcionar Que la casa se incendió a causa del corto en el enchufe Ambos son casos en los cuáles decimos que A *es una explicación de* B.

Salmon hizo notar en «Statistical Explanation» que una teoría de la explicación científica debe satisfacer CA «Statistical Explanation». Salmon argumenta que el modelo clásico que Hempel & Oppenheim desarrollan en «Studies in the Logic of Explanation» no satisface CA y, por lo tanto, es necesario modificar la teoría para dar cuenta de la explicación científica. Quiero resaltar que la discusión que Salmon hace del modelo de Hempel & Oppenheim y por qué no satisface CA, nace de un problema que Sylvain Bromberger discute en su artículo «Why-Questions».

Para apreciar la discusión en torno a la asimetría de la explicación, voy a comenzar exponiendo brevemente en qué consiste el modelo de Hempel & Oppenheim. Este va a ser el punto de partida desde el cual quiero trazar una historia del papel que, me parece, juega la causalidad en una teoría de la explicación científica. Elijo este punto de partida porque (i) es una teoría clásica en filosofía de la ciencia y (ii) pretendo justificar que *la asimetría de la explicación es un reflejo de la dirección causal*. En principio, no me parece controvertido afirmar que las explicaciones no son simétricas. Mas controvertido es afirmar que las relaciones causales explican perfectamente por qué esperamos esta asimetría. Es por esto último que en esta primera parte de mi anécdota —que además sirve como introducción a mi trabajo— voy a justificar la afirmación en itálicas. Para esto, comienzo haciendo un breve repaso por los títulos mencionados en el párrafo anterior.

Hempel y Oppenheim 1948, caracterizaron a la explicación científica como un argumento deductivo. Sabemos, por ejemplo, que “todos los metales se dilatan cuando se calientan.” Esta oración cuantificada universalmente implica deductivamente cualquier instancia particular en la que se cumplan las condiciones iniciales. Si las explicaciones son todas argumentos deductivos, entonces lo que explica por qué crece este pedazo de cobre cuando lo dejo sobre una hoguera, se debe a que es un caso particular de la oración cuantificada universalmente. El análisis que ofrecen estos autores sugiere que *explicar* consiste en ofrecer un argumento en el cuál derivemos una instancia particular de un cuantificador universal. En principio, esto suena un proceso simple, sin embargo, hay un par de detalles que resta especificar

En primer lugar, la oración cuantificada es crucial. Esta oración es lo que nos permite que el argumento sea deductivo: eliminando el cuantificador universal y sustituyendo la variable por una constante⁴. En segundo lugar, esta oración cuantificada debería ser la formulación lingüística de una ley natural. El hecho de que la oración sea una ley natural es lo que asegura que el argumento sea explicativo. Para ilustrar esto, consideremos la oración “todas las monedas en el bolsillo de Oscar son de \$1.” Sucede que la oración es verdadera⁵.

Supongamos que la oración es verdadera y, dado que está cuantificada universalmente, si tomo una moneda de mi bolsillo, entonces será de \$1. Pero que

⁴ Por si acaso, el argumento se formaliza $\forall x((M(x) \& C(x) \rightarrow D(x)), (M(a) \& C(a)) \Rightarrow D(a)$.

⁵ Además resulta que es siempre verdadera por antecedente falso. Pero me parece que no hace diferencia para el ejemplo.

todas las monedas de mi bolsillo tengan una denominación de \$1, pero esto no implica que hemos explicado por qué la moneda vale \$1. Pero esto es algo que sí parece estar presente en el caso del cobre.

El modelo sugerido por H&O—también llamado modelo por ley de cobertura—requiere que la oración cuantificada cumpla con las características para obtener el título de *ley de la naturaleza*⁶, de otro modo, el argumento carecería de cualquier valor explicativo. Si estas condiciones se satisfacen, entonces tendremos una oración cuantificada universalmente—que presumiblemente es la formulación lingüística de una ley natural,—que implica como instancia particular el fenómeno en cuestión que queremos explicar. Si esto sucede, entonces hemos tenido éxito ofreciendo una explicación.

Sylvain Bromberger 1966 detecta un problema con la caracterización que Hempel y Oppenheim ofrecen. Bromberger comienza argumentando que hay muchas similitudes entre explicar que este pedazo de cobre se dilata al calentarse—digamos, el fenómeno de la dilatación de los metales—y responder a la pregunta “¿por qué mi cuchara se dilata cuando la caliento?” Por ejemplo, el autor señala en la página que

... there are issues in the philosophy of science that warrant an interest in the nature of why-questions. The most obvious of these issues are whether science (or some branch of science or some specific scientific doctrine or some approach) ought to, can, or does provide answers to why-questions, and if so, to which ones.

La afirmación de Bromberger es altamente intuitiva. No es exagerado suponer que la investigación científica se dedica a responder preguntas de este tipo⁷: es más o menos claro que una explicación suele ser una respuesta a una pregunta *por-qué*.

Sin embargo, si enmarcamos el problema en los términos de Bromberger, entonces lo que el autor llama “la doctrina hemepeliana” es claramente incorrecta. El argumento procede así: supongamos que lo que dice Bromberger es verdad y que la doctrina hemepeliana es correcta. De forma inocente, le preguntamos a Cristian “¿por qué la altura del Empire State es de 381 metros?” Cristian, muy versado en funciones trigonométricas, responde de la

⁶ Se suele caracterizar a las leyes de la naturaleza como un fenómeno natural que es verdadero en todos los casos posibles, e independiente del tiempo y lugar en el que ocurre. Esta afirmación debe ser verdadera en todas las situaciones e independiente del tiempo y del lugar. Condiciones que dicha oración cuantificada debe cumplir si es que va a contar como una genuina explicación. Uno de los problemas que surgen de esto es que debemos ofrecer criterios para distinguir una ley de la naturaleza de generalizaciones universales espurias (Nagel, 1962). Ahora, es una cuestión distinta, si de hecho hay algo que cumpla las condiciones para ser una ley de la naturaleza. Ambos problemas son tangenciales a mi proyecto, y no discutiré más aquí. El lector interesado puede revisar (Carroll, 2024)

⁷ Por supuesto, es una afirmación completamente distinta si la investigación científica *puede* responder a *todas* las preguntas de este tipo; otra cuestión distinta es si la ciencia *debe* responder a *todas* las preguntas de este tipo. Sería muy triste una respuesta afirmativa a la segunda cuestión.

siguiente manera: hay un punto en quinta avenida que está a x distancia del Empire State. Dado el ángulo que forman los rayos de sol desde el punto más alto del edificio hasta ese punto, podemos derivar fácilmente la altura del edificio usando la función tangente.

El argumento en este caso es claramente deductivo. Si sustituimos las variables pertinentes, podemos adecuadamente concluir cuál es la altura del Empire State: resultado nada trivial. Pero esto significaría que usando este argumento, Cristian ha respondido adecuadamente *por qué* la altura del Empire State es de 381 metros, pero nadie diría que el hecho de que el ángulo que forman los rayos del sol sea θ y que la distancia entre el edificio y quinta avenida sea x , explica por qué el edificio mide 381 metros. Que el edificio tenga esa altura particular es algo que debería explicar la persona que diseñó el edificio. Esto no es culpa de Cristian, sino de quién afirme que dicha respuesta es una genuina explicación de la altura del edificio.

El problema que Bromberger detecta es que contraejemplos como éste muestran que hay que abandonar la doctrina hempeliana, y que por lo menos es necesaria una caracterización distinta de la explicación científica. Hay que notar que Bromberger discute este⁸, y otros contraejemplos en (Bromberger, 1966), pero Wesley Salmon fue quien se concentró en mostrar que el contraejemplo de la sombra implica que, si la doctrina hempeliana es correcta, entonces la explicación científica es simétrica. Una clara falta a CA y si este argumento es sólido: el modelo por ley de cobertura de Hempel y Oppenheim debe ser incorrecto. Durante este periodo de la filosofía, muchos esfuerzos se concentraron en resolver este y otros problemas derivados de la doctrina hempeliana.

Wesley Salmon empleó el contraejemplo presentado por Bromberger y mostró que el modelo por ley de cobertura implica esta simetría. Pero Salmon no sólo se dedicó a señalar los problemas del modelo por ley de cobertura, sino que formuló una teoría de la explicación que lidia con dicha asimetría y que una mejor alternativa a la teoría de la explicación desarrollada por Hempel y Oppenheim.

Wesley Salmon 1970 comienza por afirmar que la asimetría temporal es crucial para la explicación científica. Polemizando el contraejemplo de Bromberger, Salmon señala que

Although the sun, flagpole, and shadow are perhaps commonsensically regarded as simultaneous, a more sophisticated analysis shows that physical processes going on in time are involved. Photons are emitted by the sun, they travel to the vicinity of the flagpole where

⁸ El ejemplo del poste no aparece en ninguno de sus escritos, porque originalmente Bromberger no estaba atacando la asimetría que surge de la doctrina Hempeliana. La historia muestra que el ejemplo del poste se lo comentó a Hempel en una conferencia, como señalan en (Egré, 2018), anécdota mencionada también en (Dewulf, 2022, p. 81). La intención de Bromberger estaba enfocada en la semántica de las oraciones interrogativas y la ignorancia racional, tal como muestran sus trabajos posteriores (Bromberger, 1992).

some are absorbed and some are not, and those which are not go on to illuminate the ground (Salmon, 1970, p. 72)

Esto, por supuesto, resolvería el problema de la asimetría. A primera vista, es obvio que los procesos físicos tienen cierta dirección temporal⁹. Suena sensato pensar que cualquier explicación que podamos ofrecer de un fenómeno, debe respetar dicha dirección.

Sin embargo, basar la asimetría de la explicación en la asimetría temporal de los procesos físicos parece que va colando a las relaciones causales en nuestro análisis. Pero Hempel y Oppenheim querían excluir a las relaciones causales de su análisis de la explicación científica, por lo que hay que justificar dicho cambio. Esto significa que debo justificar por qué las relaciones causales comienzan a tomar un papel prominente en la explicación científica. Para hacer esto con éxito, debo recordar al lector que la discusión de Salmon está enmarcada dentro de la teoría de la explicación científica que él mismo desarrolla. Salmon busca resolver los problemas de la teoría de Hempel a la luz de considerar la asimetría de la explicación.

Para explicar brevemente en qué consiste la solución de Salmon, voy a comenzar con un ejemplo. Supongamos que queremos saber si un dado está cargado. Si lanzamos un dado icosaédrico, el dado sólo va a mostrar una de sus caras en cada lanzamiento y el resultado será un número entre 1 y 20. Este es el espacio de *eventos* definido para nuestro experimento.

Supongamos que lanzamos el dado 50 veces y generamos una lista de los resultados obtenidos. Obviamente el dado sólo puede mostrar una cara a la vez, lo que implica que cualquier otro evento—las caras que no se muestran—están excluidas una a una. Es decir, si una cara cualquiera del dado aparece, entonces el dado no muestra ninguna otra cara. En este caso, el conjunto de los posibles resultados está definido por el conjunto de números entre 1 y 20. Sabemos además que cualquiera de las caras puede aparecer por lo menos 1 de cada 20 tiradas.

Sucede que he estado usando dados icosaédricos de vez en cuando—probablemente jugando D&D—y supongamos que visito a Mar. Mar toma un dado de su colección y me propone una apuesta: cada vez que el dado muestre un número non, ella me paga \$10, mientras que yo le pago la misma cantidad cada que sale un número par. Por alguna razón, durante las 50 tiradas, los números pares aparecen con más frecuencia—digamos $\frac{15}{20}$ —por lo que estoy comenzando

⁹ Hay una discusión en torno a si hay una dirección privilegiada del tiempo, o si las relaciones temporales pueden revertirse. Esto es un tema en su propio derecho y necesitaría un trabajo mucho más largo que le hiciera justicia al tema. El lector interesado puede consultar el artículo clásico de Russell para un argumento antirrealista de la causalidad (Russell, 2015). El argumento de Russell descansa en el hecho de que las igualdades en física son reversibles. Con respecto a Hempel y Oppenheim, Se suele asumir que los empiristas lógicos basaron sus argumentos escépticos, en los argumentos clásicos de Hume, argumentos que aparecen en (Hume, 1784). Para una discusión general en torno a la dirección del tiempo, la llamada “flecha del tiempo”, el lector puede revisar (Dowden, 2023), un argumento a favor de la retrocausalidad lo ofrece Dummet en (Dummet, 1978).

a perder grandes cantidades de dinero: tengo la sospecha de que el dado está cargado.

Recapituyendo el ejemplo: lo que quiero explicar es por qué los números pares están apareciendo con más frecuencia, y parece sensato pensar en que una explicación posible es que el dado está cargado. Siguiendo las etiquetas clásicas, el *explanans*—aquello que quiero explicar—es por qué (M) Mar está ganando 15 de 20 tiradas; mientras que el *explanandum*—aquello que presentamos como evidencia, justificación, hipótesis, la respuesta a la pregunta, etc—es que (D) el dado está cargado. Llamemos *clase de referencia* a las condiciones que parten el espacio de probabilidad en dos clases mutuamente excluyentes: que el dado esté cargado $P(D)$ o que el dado no está cargado $P(\neg D)$. Suele suceder que los dados cargados muestran algunos números con más frecuencia que otros, entonces C es estadísticamente relevante para M , y si esto es verdad, entonces, $P(M|C)$ debería ser mayor que $P(M|\neg C)$.

En corto, la *clase de referencia* parte el espacio de eventos en las variables que sospechamos hacen una diferencia estadística. Una parte de la solución, que desarrolla Salmon, comienza por hacer clara la definición de la clase de referencia. Brevemente, la clase de referencia es el conjunto que usamos para definir el espacio de eventos y seleccionar las variables estadísticamente relevantes.

Por ejemplo, supongamos que queremos explicar por qué hoy hubo una tormenta. Nuestra clase de referencia es el conjunto de días en los que hubo tormentas y las condiciones que estuvieron presentes mientras el fenómeno ocurría. Que disminuya la presión atmosférica suele indicar que se aproxima una tormenta, lo que significa que podemos dividir la clase de referencia en los días en los cuáles hubo una tormenta y disminuyó la presión atmosférica, y aquellos días en los que hubo una tormenta y no disminuyó la presión atmosférica. Si condicionamos el evento a una de estas dos clase de referencia y descubrimos que una de ellas es relevante para el hecho de que llueva, entonces esto explica por qué hoy hubo una tormenta, cuya respuesta es, porque disminuyó la presión atmosférica.

Salmon considera que la clase de referencia que hemos definido, debe ser *homogénea* y debe ser la *más amplia*, es decir, que incluya todas las variables estadísticamente relevantes—mientras excluimos las variables irrelevantes—para que el fenómeno en cuestión ocurra. Retomando el ejemplo, podemos hacer más estrecha la clase de referencia al introducir variables como la velocidad del viento, las condiciones de humedad, la época del año, etc. Para mi ejemplo simple, la frecuencia de (A) los días en que hubo lluvia, (B) disminuyó la presión atmosférica y (C) hubo velocidades de viento arriba de los $80km/hr$, resultando en $P(A|B\&C)$. Agregar estas variables, vuelve más estrecha a la clase de referencia.

Regresando a la teoría de la explicación que Salmon desarrolla, hay ciertas condiciones que la respuesta a la pregunta “¿Por qué llovió hoy?” debe cumplir para que cuente como una explicación genuina. En primer lugar, debemos definir la clase de referencia. En segundo lugar, tenemos que elegir qué condiciones son estadísticamente relevantes para que ocurra el fenómeno, de manera que seamos capaces de incluir todas las variables. Por último, las va-

riables deben ser estadísticamente relevantes para el fenómeno en cuestión. De esta manera hemos elegido las variables que *hacen una diferencia* para que el fenómeno ocurra. Esta diferencia está definida de la siguiente manera: si $P(A|B) \neq P(A|\neg B)$ ¹⁰, y C es una variable estadísticamente relevante—una variable que hace una diferencia—entonces la respuesta a “¿Por qué llovió el día de hoy?”, sería “Porque disminuyó la presión atmosférica y hubo vientos arriba de 80 Km/h”. Dado que estamos asumiendo que estas variables son estadísticamente relevantes, entonces debería cumplirse que $P(A|B \& C)$ es mayor que cualquiera entre $P(A|\neg B \& C)$, $P(A|B \& \neg C)$, $P(A|\neg B \& \neg C)$. Es gracias a que seleccionamos una clase de referencia adecuada—en la cuál están incluidas las variables que de hecho *hacen una diferencia*—que podemos explicar la ocurrencia del evento A a partir de la ocurrencia de B y C .

Antes de continuar con la exposición, quiero recapitular los detalles del modelo de Salmon. Primero, debemos ser capaces de hacer una “partición homogénea” del fenómeno a explicar. Que sea una partición homogénea significa que dado el fenómeno que queremos explicar, debemos seleccionar todas las variables relevantes que hagan una diferencia para que el evento ocurra. Esta partición debe ser exhaustiva, es decir, que no falte ninguna variable relevante por incluir y que no sea posible agregar nuevas variables al conjunto. En palabras de Galavotti “En esta perspectiva lo que cuenta para la explicación no es la alta probabilidad, como lo requería Hempel, sino estar en posición de afirmar que la distribución de probabilidad asociada con el *explanandum* refleja la información más completa y detallada que podamos obtener”¹¹ (Galavotti, 2022).

Hasta aquí, el modelo de explicación defendido por Salmon tiene una serie de ventajas. El modelo resuelve muchos de los problemas que tiene el modelo por ley de cobertura: la noción de explicación que desarrolla Salmon no echa mano de leyes y, por tanto, no tiene el problema de distinguir entre leyes y generalizaciones accidentales. Además, evitar que la explicación descansa en la noción de *ley de la naturaleza*, se antoja más adecuado para analizar las explicaciones en aquellas ciencias en las que no es obvio que haya tal cosa (como la biología o la economía).

Sin embargo, aún resta un problema por sortear: que seamos capaces de seleccionar las variables pertinentes, no implica que la relación temporal definida sea la correcta. Supongamos que hay una cadena temporal entre el aumento de la velocidad del viento, la disminución en la presión atmosférica y, por último, que llueva. Llamemos a esta descripción D . Sin embargo, hay otra manera—perfectamente sensata—de describir esta relación temporal: supongamos ahora que tanto la disminución en la presión atmosférica y el aumento del viento ocurren al mismo tiempo, luego llueva. Llamemos a esta descripción D' .

¹⁰ Estoy asumiendo que de hecho hay una diferencia en la frecuencia. Si no la hubiera, es decir $P(A|B) = P(A|\neg B)$, entonces la relevancia sería la misma que una tirada de moneda, por los axiomas 2 y 3 de Kolmogorov.

¹¹ In this perspective what counts for the sake of explanation is not high probability, as required by Hempel, but being in a position to assert that the probability distribution associated with the explanandum reflects the most complete and detailed information attainable.

Si asumimos que seleccionar las variables relevantes es *suficiente* para caracterizar a la explicación científica, entonces ambas descripciones constituyen explicaciones correctas. Más aún, esto implica que D y D' son explicaciones equivalentes. Sin embargo, intuitivamente, D y D' describen fenómenos completamente distintos. Mientras que D parece sugerir que la baja en la presión atmosférica *causa* el aumento en la velocidad del viento y esto a su vez *causa* que llueva, D' parece sugerir que tanto la baja en la presión atmosférica y el aumento en la velocidad del viento *causan* que llueva.

Esto significa que el modelo de Salmon aún tiene problemas relacionados con distinguir cadenas temporales. Este problema obviamente le preocupa al autor, como muestra la cita casi al inicio de esta sección, porque Salmon reconoce que el modelo tal como está expuesto, es claramente sensible a hacer pasar las correlaciones estadísticas por relaciones de dependencia causal¹²

En estadística, es más que común el eslogan “correlación no implica causalidad” y el problema con el análisis de Salmon, tal como lo he presentado hasta aquí, es que no hay manera de distinguir entre las correlaciones que tienen una causa común. Sé que para determinar cuál es la presión atmosférica, puedo utilizar un barómetro. Sé además que cada vez que el barómetro se comprime, es porque ha aumentado la presión atmosférica. Obviamente la lectura del barómetro es relevante para que se den condiciones de lluvia, pero la variable causalmente relevante es la presión atmosférica, no la lectura del barómetro. Si ingenuamente comienzo a mover con mi mano la aguja del barómetro—mientras todas las demás condiciones permanecen constantes,—es claro que no he aportado a la producción de lluvia: el barómetro no es un factor causal relevante.

Sin embargo, sabemos que la lectura del barómetro *es* una variable estadísticamente relevante, que *hace una diferencia* (tal como lo he definido líneas arriba) en el resultado esperado¹³, pero es claro que he seleccionado un factor *causalmente* irrelevante, aún cuando es un factor *estadísticamente* relevante. Si sólo caracterizamos a la explicación como he hecho hasta aquí—exponiendo la teoría que Salmon presenta en (Salmon, 1970)—entonces vamos a ganar casos que cumplen las condiciones, pero que no son explicaciones.¹⁴ Para resolver este problema, Salmon hace notar que su modelo de explicación puede naturalmente incorporar *relaciones causales*. De este modo, en torno al ejemplo de la sombra, Salmon comenta que

The reason that the explanation of the length of the shadow in terms

¹² Salmon discute e intenta resolver esto apelando a los estados de baja entropía y a la relación temporal entre el evento a explicar y la clase de referencia. No voy a detallar la solución que Salmon propone, porque no es necesario para fines del proyecto. El lector interesado puede leer la última sección de (Salmon, 1970).

¹³ No estoy seguro de que todas las personas que se dedican al clima tienen barómetros funcionales que usan cotidianamente para medir la presión atmosférica, pero puedo apostar a que usan las lecturas de sus barómetros para determinar si va a llover o no, y que cuando hay una baja en la lectura del barómetro (y otras condiciones relevantes para el caso), es porque de hecho va a llover.

¹⁴ obviamente no siempre es bueno ganar, especialmente si lo que hemos ganado es basura.

of the height of the flagpole is acceptable, whereas the “explanation” of the height of the flagpole in terms of the length of the shadow is not acceptable, seems to me to hinge directly upon the fact that there are causal processes with earlier and later temporal stages. (Salmon, 1970)

Lo que sugiere la cita anterior es que para responder a estos problemas, deberíamos incluir factores causales en nuestro análisis. Esto es una clara desviación de lo que se suele asumir eran tesis básicas del antaño positivismo lógico. Mucho esfuerzo filosófico se dedicó al tema de la causalidad y la explicación. Relevante para este contexto, por ejemplo, es que Lewis publicó «Causation»; *Counterfactuals*; mientras que en torno al fenómeno de la explicación, Friedman publicó «Explanation and Scientific Understanding». Otros esfuerzos fueron dedicados a hacer claro si es que la causalidad juega un papel en la explicación científica, y cuál es dicho papel (Kitcher, 1962). Siguiendo algunas de las soluciones que ofreció Salmon al resolver el problema de la asimetría—entre ellas el hecho de que su modelo de explicación no necesita definir qué es una ley de la naturaleza—muchos filósofos han tratado de ofrecer una teoría de la explicación científica que incluya un factor causal en su análisis. Tal es el caso de James Woodward.

James Woodward 2004 ha desarrollado una teoría de la explicación científica que hace exactamente esto: incluir relaciones causales. La teoría de Woodward, por razones que espero queden claras en los siguientes párrafos, ha recibido el nombre de *manipulabilista*. Brevemente, las teorías *manipulabilistas*¹⁵ afirman que dadas dos variables A y B , decimos que A *causa* B si al intervenir (manipular) la variable A , la variable B cambia en consecuencia. Me voy a permitir formular un ejemplo que, espero, haga claros los detalles de esta teoría.

Asumamos que Miranda me pregunta por qué hoy llovió y estoy tratando de formular una respuesta. Retomando las descripciones D y D' definidas anteriormente, puedo formular dos respuestas. Suponiendo D , debería buscar información de cómo se producen los vientos y si la presión atmosférica está relacionada en su producción¹⁶, después de tener la información pertinente, entonces podría responderle a Miranda señalando que cuando la (A) presión atmosférica *aumenta*, *produce* cambios en la (B) velocidad del viento, lo que a su vez *causa* que (C) llueva. Las palabras enfatizadas en esta oración, son palabras que intuitivamente relacionamos con procesos causales: palancas, poleas y manivelas. Al ofrecer esta respuesta, parece que asumo que hay un proceso

¹⁵ La siguiente caracterización está basada en (Woodward, 2000, 2004; Ross & Woodward, 2023; Woodward, 2023).

¹⁶ Resulta que es la termodinámica del ambiente jugando un papel más complejo. Lo que sucede es que vientos veloces distribuyen mejor el calor, lo que enfría el aire y lo vuelve más denso, lo que aumenta la presión atmosférica (Spiridonov & Ćurić, 2021). Esto implica que la respuesta que voy a dar es incorrecta, pero esto no afecta los fines expositivos.

causal participando. Es decir que son variables que considero¹⁷ son causalmente relevantes para dar una explicación de por qué llovió hoy.

Si modeláramos el evento¹⁸ señalando que hay una relación proporcional entre la presión atmosférica y la velocidad del viento, de tal suerte que un aumento de 1 en la presión atmosférica, implica un aumento de 10km/h en la velocidad del viento; además, sucede que siempre llueve cada que la velocidad del viento es mayor a los 85km/h, o dicho de otro modo, “si aumentáramos en 9 unidades la presión atmosférica, entonces llovería.”

Con el ejemplo anterior, sólo pretendo señalar la parte más intuitiva de las teorías manipulabilistas, que ciertos cambios en los valores de las variables provocan cambios en los valores de otras variables: pero sólo a través de este cambio. Esto, por supuesto, sólo es una parte de la historia de las dichas teorías. Olvidémonos por un momento de la presión atmosférica y supongamos que el fenómeno a analizar es uno completamente estable, es decir, que cualquier cambio de valor en la variable A , implica un cambio *proporcional* en B . Si hay una función bien definida sobre un conjunto, la tarea es ligeramente sencilla. Definamos una función cualquiera de una variable tal que $f(x) = 2x$, donde $x \in N$. Esto significa que si la función toma el 9 como valor de entrada, el valor de salida será 18. Supongamos más aún que estos son los valores de una medida de fuerza y que la relación es la siguiente: si la fuerza A es de 1 unidad, entonces la distancia B trasladada de un proyectil es de 2.¹⁹ Digamos entonces que aplicar 3 medidas de fuerza, producen *6 metros* de distancia de un proyectil. Supongamos además que esta función es *independiente* de cualquier fuerza externa, por ejemplo, de la resistencia del medio (en este caso el aire), el ángulo de lanzamiento (dependiendo del ángulo, la gravedad comienza a jugar un papel), etc. Un teórico de la aproximación causal intervencionista, diría que esto significa que la fuerza impresa en el proyectil, *causa* que el proyectil alcance más distancia. Además diría que es posible que la función definida anteriormente no describa esta relación para algunos de los valores de A , por ejemplo, si imprimo una fuerza de $1 * 10^{-7}$ unidades, seguramente el proyectil no se traslade $2 * 10^{-7}$ unidades.

El ejemplo anterior me sirve para describir algunas de las características de la teoría *manipulabilista*. Que la función describa correctamente el comportamiento del proyectil, *independiente* de otras fuerzas, quiere decir que la fuerza impresa en el proyectil es la única variable causalmente relevante que afecta la distancia del mismo. Que la *intervención* en la fuerza impresa cause que el proyectil llegue a mas distancia —*independiente* de cualquier otra fuerza—significa que en la medida de los posible hemos decidido dejar fuera del modelo, variables *exógenas*, variables que sabemos pueden afectar el comportamiento del modelo,

¹⁷ Insisto aquí en la palabra *considero*. Esto quiere decir que no significa que *sé* que dichas variables son causalmente relevantes, sino que *especulo* que son variables pertinentes.

¹⁸ Algo que saben hacer los meteorólogos profesionales. Yo carezco del conocimiento para hacer un modelo mínimamente informativo, por tanto, el ejemplo es de juguete. Lo cuál no afecta los fines explicativos.

¹⁹ Por supuesto esto es púramente ficticio, se trata sólo de un ejemplo ilustrativo, el punto es que la función de distancia es proporcional a la medida de fuerza.

pero al decidir concentrarnos en la fuerza y la relación con la distancia, dejamos dichas variables fuera. Si además podemos excluir todas las variables, excepto la fuerza, entonces es posible hacer una intervención *quirúrgica* y que sólo haya ciertos valores que describen correctamente el comportamiento del proyectil, significa que es *invariante* bajo un rango de intervenciones. Es en esto, a grandes rasgos, en lo que consiste una teoría *manipulabilista* de la causalidad.

Por supuesto, otras características integran a la teoría, además de que muchos argumentos se han presentado para mostrar sus deficiencias de la causalidad. Quizás la más controversial de ellas es que la teoría hace uso de condicionales *contrafácticos*.

Los condicionales *contrafácticos* son aquellos condicionales que evaluamos asumiendo que algo de *hecho*, no sucede. Esto nos obliga a preguntarnos qué pasaría si se cumplieran ciertas condiciones particulares. Dicho de otro modo, nos preguntamos cómo sería el mundo si, por ejemplo, México *no hubiera sido conquistado* por los españoles.

Parece más que natural implementar estos condicionales en la teoría intervencionista de la causalidad. Al definir las variables causalmente relevantes, podemos incluir tanto variables discretas como variables continuas y podríamos analizar preguntas del tipo “¿qué hubiera sucedido si *A* hubiera tomado un valor distinto al que tomó, digamos 0.08?” Si la función está bien definida, como en mi ejemplo, entonces es relativamente sencillo determinar valores de distancia para diferentes valores de fuerza.

Esto es algo que no sólo es parte de la teoría manipulabilista de la causalidad, sino que suele mencionarse en contextos de investigación científica. Cuando se analizan modelos estadísticos, los autores suelen mencionar condicionales *contrafácticos* como parte de sus análisis. Entre estas herramientas, resalta especialmente *la inferencia causal*, que es una herramienta estadística usada para derivar conclusiones causales a partir de agregación de datos e inferencia estadística. Estos métodos sirven, sobre todo, para determinar cuáles factores son causalmente relevantes (Pearl et al., 2016; Pearl & Mackenzie, 2018).

Pensemos, por ejemplo, en las *Pruebas Controladas Aleatorizadas* (RCT, por sus siglas en inglés), donde típicamente, los investigadores interesados en saber cuál es la efectividad de un medicamento, intervienen en una de las variables—dándole un placebo a un grupo de control, mientras que otro grupo recibe el medicamento a testar. Asumiendo que no hay sesgos en la muestra, si el grupo de prueba responde al medicamento, entonces, en principio, seremos capaces de detectar si el medicamento hace una aportación causal. En corto: que podemos pensar que el grupo de control funciona como una especie de imagen alterna de lo que *habría* pasado de no haber tomado los medicamentos.

Si bien, aún no hay un consenso universal de que la causalidad *deba* ser parte de nuestras teorías de la explicación científica, con la discusión anterior quiero sugerir y motivar que la causalidad es una característica fundamental del proceso de explicación científica. Consolidando mi intuición original de que la causalidad de hecho juega un papel en la explicación.

Parte II

Hasta este momento de la anécdota, me he concentrado en repasar rápidamente algunas de las teorías de la explicación clásicas en filosofía de la ciencia. Como bien confesé al inicio, tengo mis preferencias en torno a qué teoría de la explicación es la más adecuada. Pero quiero llamar la atención en torno a que en la última de las teorías expuestas, el tema viró hacia los condicionales contrafácticos. Son este tipo de condicionales los que ocupan mi trabajo de investigación actual.

Es más que obvio que los condicionales contrafácticos están en la caja de herramientas de cualquier persona que se dedica a hacer estadística en su trabajo diario, por tanto, los *condicionales contrafácticos* son un elemento de la *investigación científica*.

Pensemos en ejemplos donde aparecen herramientas de este tipo, como en los métodos de *inferencia causal*. Herramientas como los modelos de inferencia causal, son usados regularmente para aislar factores causales a partir de agregados de datos e inferencia estadística. Los investigadores tenemos un interés particular por aislar factores causales, por ejemplo, para saber qué factores afectan causalmente el desempeño académico de los estudiantes, o para intervenir en factores que promuevan el aumento de los salarios y la calidad de vida, etc. La inferencia causal modela fenómenos causales haciendo uso de *contrafácticos*, que se presentan como eventos alternos que tienen exactamente las mismas condiciones, pero variamos la cantidad de la variable que creemos está haciendo el trabajo causal. El amplio uso de estos métodos, así como algunas de las aplicaciones que tienen en la investigación científica es algo que queda reflejado en (Pearl et al., 2016), en (Pearl & Mackenzie, 2018) y especialmente en (Llaudet & Imai, 2023).

Sin embargo, el hecho de que los contrafácticos sean parte de estos métodos y que su uso sea cotidiano en investigación, no significa que estén resueltos todos los problemas filosóficos que acarrearán. En este trabajo de investigación, me voy a dedicar a discutir el problema que ha recibido el nombre de “el problema fundamental de la inferencia causal.” Dicho en una oración: que no es posible saber el valor de verdad de un condicional *contrafáctico*. Si por definición del condicional, estamos evaluando algo que no sucede, pero que pudo haber sucedido: exactamente qué evidencia podemos ofrecer para justificar condicionales como “si los españoles no hubieran conquistado México, entonces conservaríamos todas nuestras reservas de oro.”

Esto, por supuesto, es un problema relacionado con la epistemología de la modalidad. Para ejemplificar el problema, supongamos que queremos saber si los estudiantes que leen más de un libro al año tienen un mejor desempeño académico que aquellos alumnos que leen menos de un libro al año. Supongamos, más aún, que hemos diseñado una prueba aleatoria randomizada y que hemos aislado existosamente la variable “leer más de un libro al año”, que en la encuesta probablemente midamos con el con la pregunta proxy “¿lee usted más de un libro al año?”

Ahora, si nos preguntamos qué hubiera sucedido si los alumnos no leyeran

al menos un libro al año, debemos responder a la pregunta “¿qué habría pasado si...?”, lo que significa que tenemos que evaluar el desempeño del grupo de control, es decir: aquel que leyó menos de un libro al año. Sin embargo, la única información que tenemos es el agregado estadístico de los alumnos que leyeron menos de un libro al año, lo que implica que nunca seremos capaces de observar, digamos, qué hubiera sido de Ana si hubiera leído menos de un libro al año; ni siquiera seremos capaces de observar que hubiera sido de *cualquier* alumno dentro del grupo de control: en breve, no podemos hacer que Ana lea más de un libro al año, rebobinar, incentivar a Ana a leer menos, luego observar en resultado en ambos casos.

Si somos personas trabajando en una hipótesis para saber cómo la lectura afecta el desempeño de los estudiantes, estas estadísticas sólo muestran que los alumnos que leyeron más de un libro al año tuvieron un mejor desempeño académico que aquellos alumnos que no lo hicieron. Pero esto no es suficiente para justificar que la directora de la escuela le recomiende a Ana leer más de un libro al año *mejora*: descrito de esta manera, es al menos físicamente imposible observar a Ana leyendo al menos un libro al año, y haciendo exactamente lo contrario.

Entonces, ¿cómo sabemos que este modelo implica correctamente que incentivar el hábito de la lectura genera un mejor desempeño académico? Si no es posible observar casos contrafácticos, significa que hemos perdido una explicación causal de por qué Ana Sandoval tuvo un mejor desempeño que Jorge Monreal. Simplemente porque no podemos observar que habría sido de Ana si hubiera leído menos de un libro al año, o bien, qué hubiera sido de Jorge si hubiera leído al menos un libro al año.

Esto implica un problema acerca del significado o valor de verdad de condicionales contrafácticos que tienen como argumento un nombre propio: podemos hacer inferencias de cómo el grupo de prueba y el grupo de control difieren, y podemos determinar si esto implica una relación causal entre las variables *leer* y *desempeño académico*. Resta además señalar exactamente cuál es el papel que juegan estas variables y cómo. Por ejemplo, es completamente plausible que *obligar* a los estudiantes tenga una efectividad diferente a *incentivar* a los estudiantes. Por supuesto, quienes usan este tipo de métodos en su investigación tienen presente que con hemos perdido causas particulares, pero creo que todos podemos acordar que estos métodos son en efecto explicativos y que es importante aislar factores causales.

Por el momento, no voy a entrar en detalles sobre qué son y cual es la naturaleza los condicionales contrafácticos, porque eso ya es parte de mi proyecto, por ahora sólo basta mencionar que los condicionales contrafácticos encuentran su aplicación en estos contextos para, digamos “crear” un evento alterno (si asumimos que no hay sesgos en los grupos de control y de prueba, y que hemos eliminado causas comunes dentro de nuestro análisis), en principio, seremos capaces de derivar una conclusión causal Pearl et al., 2016; Otsuka, 2023.

Podemos encontrar en la literatura contemporánea teorías de la explicación científica que incluyen factores causales. Por ejemplo, Potochnik nos dice que “[...] I make the case that much of science is profitably understood as the

search for causal patterns. ” (Potochnik, 2017, p. 24)

Este “espíritu causal” nota incluso en libros de texto. Por ejemplo, cabe notar que en Pearl et al., 2016, los autores inician señalando que la causalidad *debería* ser empleada en nuestras explicaciones estadísticas, en la página 1, los autores comentan

We study causation because we need to make sense of data, to guide actions and policies, and to learn from our success and failures. We need to estimate the effect of smoking on lung cancer, of education on salaries, of carbon emissions on the climate.

Un poco más adelante, nos dicen que

When approached rigorously, causation is not merely an aspect of statistics; it is an addition to statistics, an enrichment that allows statistics to uncover workings of the world that traditional methods alone cannot.

No voy a hacer una defensa de la teoría *manipulabilista* de la causalidad. Eso lo hice en mi proyecto de maestría—sea cual sea el éxito que haya tenido esta defensa—, en particular, intenté elucidar cómo una teoría manipulabilista lidia con explicaciones causales en biología evolutiva. Mi proyecto actual nace de preocupaciones que restaron de ese proyecto. En particular, si es verdad que en la investigación científica se hace uso de condicionales contrafácticos, entonces vale la pena preguntarse (i) *¿cómo sabemos qué condicionales contrafácticos son “verdaderos”?* .

Hay mucho que desempaquetar en la pregunta (i). Primero, la pregunta es parte de un condicional, esto es intencional. De este condicional quiero extraer la conclusión de que de hecho vale la pena esa pregunta. Presentar este condicional es parte de la motivación del proyecto. Hasta ahora he mencionado brevemente las aplicaciones que hacen mención de contrafácticos, lo cual ofrece una motivación para preguntar (i). Supongamos por un momento que dichos condicionales de hecho son parte de la investigación —digamos que son parte de los métodos que usan los investigadores. El capítulo 1 lidia con cómo estos condicionales son y 2 lidian con No sólo eso, sino que responder a (i) equivale a explicar por qué la conclusión tiene sentido, de acuerdo al marco teórico en el que se desarrollará.

Mi proyecto se concentra en resolver por qué *la verdad* juega un papel importante en la investigación científica y luego en cómo *justificar* qué condicionales contrafácticos cumplen este criterio. Mi proyecto se concentrará en el contexto de las inferencias causales, y cómo echan mano de *condicionales contrafácticos*. Si son estos condicionales los que nos permiten trazar relaciones causales según la teoría *manipulabilista*, entonces más nos vale saber cómo determinar el valor de verdad. Una motivación que se suele mencionar en la literatura para introducir estos métodos es la llamada “paradoja de Simpson.” Esto no es estrictamente una paradoja, pero aparece cuando los datos se

comportan de manera poco intuitiva (Hájek & Hitchcock, 2016, p. 13), Algunos autores han señalado que la solución radica en ser capaces de ofrecer un método para obtener relaciones causales a partir de datos estadísticos.

Este tema –el de la explicación causal– está fuertemente vinculado con el uso de herramientas y *modelos* estadísticos en investigación. Mi propósito en este trabajo es hacer claro cómo funcionan dichos modelos y qué herramientas nos sirven para justificar que en efecto dos variables están causalmente relacionadas. Esto es importante, porque en muchos casos se suele decir que los *modelos* usados en investigación, sea cual sea su uso, son “falsos”, sentido que suele expresar como “[...] models typically only hold *approximately*, in some ranges of circumstances, and they liberally employ idealizations to accomplish this *partial* fit.” (Potochnik, 2017, p. 18, énfasis agregado) Potochnik también afirma que buena parte de la investigación se centra en ofrecer explicaciones causales y, más aún, afirma que una buena manera de lidiar con explicaciones causales en investigación científica es adoptando una teoría causal *manipulabilista*, algo con lo que estoy completamente de acuerdo, como espero haya quedado claro. Potochnik también defiende que el uso de modelos en investigación –y cualquier supuesto que imponga ciertas condiciones en el modelo– surge de la necesidad de que seres con capacidades cognitivas limitadas queramos representar fenómenos naturales para aislar los factores causales bajo escrutinio. Es importante poner énfasis en esto porque implica que los modelos *son generados* con ciertos objetivos en mente, o como ella misma señala “[...] the nature of these idealizations is relative to the aim of research, as is most clearly demonstrated by the different idealizations involved in the various approaches to human aggression research. ”

Mi investigación actual lidia con cómo *determinar* el valor de verdad de condicionales contrafácticos, usados para formular hipótesis estadísticas, hipótesis que se justifican haciendo uso de modelos —a veces modelos de inferencia causal, o de otro tipo—, mientras afirmamos que los modelos son falsos. En principio, este no es un problema grave si la “verdad” no es una parte central de la investigación científica (en cualquier disciplina).

Pero si la investigación se propone *justificar* hipótesis para obtener *conocimiento* de relaciones causales reales, entonces tenemos un problema. ¿Cómo los modelos, que no representan adecuadamente el fenómeno, pueden dar como resultado nuevo conocimiento? El problema, me parece, radica en la discusión en torno a la representación. La relación que guarda el modelo con el objetivo que pretende representar.

Mi hipótesis es que cierta forma de verdad debe estar involucrada en nuestra definición de *conocimiento*, si es que queremos que las intervenciones en un sistema sean de alguna utilidad. Por ejemplo, si el aumento del salario mínimo causa un aumento en el desempleo y qué condiciones juegan un papel causal en dicha relación.

Regresando a la anécdota, el hecho de que estos dos profesores buenos trabajaran filosofía de la ciencia –al menos lo que en ese momento creía que

era la filosofía de la ciencia— sesgó mis intereses a lo que hasta ahora ha sido mi trabajo. La influencia de estos dos profesores me hizo tomar la decisión de entrar al posgrado en Filosofía de la Ciencia.

En las clases de maestría hubo profesores excelentes. Mucho de lo que aprendí en estos cursos me sirvió para enmarcar de diferente manera las preguntas que me preocupaban, lo cuál me permitió entender —mejor, me parece— la naturaleza de la investigación científica. En particular quería responder preguntas sobre la epistemología de la ciencia, preguntas del tipo: “¿qué estamos justificados a creer?”, “¿cuándo podemos afirmar que una hipótesis ha sido corroborada?”, “¿es la explicación o comprensión más básica que el conocimiento?”, etc. Preguntas que surgen a partir de mi interés por la explicación causal.

Ahondar en estas preguntas y tratar de responderlas es una tarea más que complicada. Muchos de los obstáculos se deben a que la práctica científica es más caótica y heterogénea de lo que parece en un principio. Incluso si nos concentramos en el uso de herramientas estadísticas o herramientas que echan mano de la teoría de la probabilidad, en casi todos los casos, ciertas propiedades del *fenómeno en cuestión* son idealizadas o ignoradas para hacer que el modelo estadístico sea de utilidad.

Esta representación parcial del fenómeno se debe a que en muchos casos buscamos destacar algunas propiedades particulares del fenómeno, sin que todas las variables estén representadas en el modelo. Que no involucremos todas y cada una de las variables que afectan el fenómeno es un reflejo de nuestra limitada capacidad cognitiva. A lo largo de su escrito, Potochnik nos recuerda que los modelos diseñados en la investigación científica tienen un propósito particular. Son usados para destacar algunas propiedades particulares, especialmente, especialmente si lo que nos interesa son las relaciones causales. Que simplifiquemos de ciertas manera el modelo se debe a que los investigadores intentan resaltar las características de un fenómeno en un momento particular.

Potochnik no es la única que ha señalado esto, Abrams (2023, p.24), por ejemplo, nos recuerda que “So-called infinite-population models are simply models that have no role for drift. Biologists do often say things about evolution in infinite populations, and these claims are usually correct: the role of this terminology *in practice* implies that it should not be understood literally.” (énfasis agregado)

A pesar de que los modelos no son completamente adecuados, —en el sentido en el que no representan totalmente el fenómeno en cuestión,— son ampliamente utilizados en la investigación científica. Si estas herramientas son usadas ampliamente, entonces como filósofos de la ciencia hay que ofrecer un análisis de cómo exactamente los modelos sirven para justificar hipótesis si parten de supuestos obviamente falsos.

Me parece que buena parte del problema está relacionado con determinar cuál es el papel que juega la *representación adecuada* y la *verdad* en la investigación científica. Para motivar mi afirmación anterior, quiero dar un repaso por un periodo de la filosofía de la ciencia, un periodo en el cuál —suele decirse— la *verdad* jugaba un papel central en los análisis filosóficos de la ciencia: me refiero

al periodo en el que los miembros del Círculo de Vienna estuvieron vivos. Este repaso sirve para motivar la afirmación de que la *verdad* juega un papel en la investigación científica —por el momento no asumiré cuál es ese papel,— mientras que esto es al mismo tiempo compatible con la “representación parcial” que hacen los modelos de un fenómeno.

Para comenzar este repaso, debo señalar que en la maestría aprendí nuevas metodologías de investigación, además de diferentes maneras de plantear y entender las preguntas que me preocupaban. Pero lo más valioso que aprendí fue la importancia que tiene la historia de la ciencia en la filosofía de la ciencia. Me voy a permitir hacer una breve caracterización, exageradamente general, de dos posturas en historia de la ciencia.

En la sección 4 de su artículo, Salmon motiva su discusión al tratar de resolver el problema del caso único. Este problema parece funesto para la interpretación frecuentista de la probabilidad (que es la interpretación que Salmon favorece a lo largo de su artículo) y su uso en explicación. Salmon cree que no es así. Para justificar esto, desarrolla un aparato teórico para tratar con dicho problema. Una parte importante de De acuerdo con Salmon, explicar un fenómeno consiste en detectar las diferentes variables —estadísticamente relevantes— para que un fenómeno ocurra.

Bibliografía

- Hume, D. (1784). *An Enquiry Concerning Human Understanding*. Early Modern Texts.
- Hempel, C. G., & Oppenheim, P. (1948). Studies in the Logic of Explanation. *Philosophy of Science*, 15(2), 135-175. <https://doi.org/10.1086/286983>
- Kitcher, P. (1962). Explanatory Unification and the Causal Structure of the World. En P. Kitcher & W. C. Salmon (Eds.), *Scientific Explanation* (pp. 410-505). University of Minnesota Press.
- Nagel, E. (1962). The Structure of Science: Problems in the Logic of Scientific Explanation. *Philosophy*, 37(142), 372-374.
- Bromberger, S. (1966). Why-Questions. En R. G. Colodny (Ed.), *Mind and Cosmos: Essays in Contemporary Science and Philosophy* (pp. 86-111). University of Pittsburgh Press.
- Salmon, W. (1970). Statistical Explanation. En *The Nature and Function of Scientific Theories*.
- Lewis, D. (1973). Causation. *Journal of Philosophy*, 70(17), 556-567. <https://doi.org/10.2307/2025310>
- Lewis, D. K. (1973). *Counterfactuals*. Blackwell.
- Friedman, M. (1974). Explanation and Scientific Understanding. *Journal of Philosophy*, 71(1), 5-19. <https://doi.org/10.2307/2024924>
- Dummett, M. (1978). ¿Puede un efecto preceder a su causa? En *La verdad y otros enigmas* (pp. 408-422).
- Bromberger, S. (1992). *On What We Know We Don't Know*. University of Chicago Press / CSLI.
- Woodward, J. (2000). Explanation and Invariance in the Special Sciences. *British Journal for the Philosophy of Science*, 51(2), 197-254. <https://doi.org/10.1093/bjps/51.2.197>
- Woodward, J. (2004, enero). *Making Things Happen: A Theory of Causal Explanation*. Oxford University Press. <https://doi.org/10.1093/0195155270.001.0001>
- Russell, B. (2015). I.—On the Notion of Cause. *Proceedings of the Aristotelian Society*, 13(1), 1-26. <https://doi.org/10.1093/aristotelian/13.1.1>
- Hájek, A., & Hitchcock, C. (Eds.). (2016). *The Oxford Handbook of Probability and Philosophy*. Oxford University Press.

- Pearl, J., Glymour, M., & Jewell, N. (2016). *Causal Inference in Statistics: A Primer*. Wiley. <https://books.google.com.mx/books?id=L3G-CgAAQBAJ>
- Potochnik, A. (2017). *Idealization and the Aims of Science*. University of Chicago Press.
- Egré, P. (2018). Sylvain Bromberger, 1924-2018.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books. <https://books.google.com.mx/books?id=EmY8DwAAQBAJ>
- Spiridonov, V., & Ćurić, M. (2021). Atmospheric Pressure and Wind. En *Fundamentals of Meteorology* (pp. 87-114). Springer International Publishing. https://doi.org/10.1007/978-3-030-52655-9_8
- Dewulf, F. (2022). *The Emergence of Scientific Explanation as a Problem for Philosophy of Science: Aristotle, Nagel, and Hempel* (M. Neuber & A. T. Tuboly, Eds.). Springer International Publishing. https://doi.org/10.1007/978-3-030-81010-8_4
- Galavotti, M. C. (2022). Wesley Salmon. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Fall 2022). Metaphysics Research Lab, Stanford University.
- Abrams, M. (2023). *Evolution and the Machinery of Chance: Philosophy, Probability, and Scientific Practice in Biology*. University of Chicago Press. <https://books.google.com.mx/books?id=piO2EAAAQBAJ>
- Dowden, B. H. (2023). Arrow of Time [[Accessed 06-05-2025]].
- Llaudet, E., & Imai, K. (2023). *Data Analysis for Social Science: A Friendly and Practical Introduction* (1.^a ed.). Princeton University Press.
- Otsuka, J. (2023). *Thinking about Statistics: The Philosophical Foundations*. Routledge, Taylor & Francis Group. <https://books.google.com.mx/books?id=JPz4zgEACAAJ>
- Ross, L., & Woodward, J. (2023). Causal Approaches to Scientific Explanation. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Spring 2023). Metaphysics Research Lab, Stanford University.
- Woodward, J. (2023). Causation and Manipulability. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Summer 2023). Metaphysics Research Lab, Stanford University.
- Carroll, J. W. (2024). Laws of Nature. En E. N. Zalta & U. Nodelman (Eds.), *The Stanford Encyclopedia of Philosophy* (Winter 2024). Metaphysics Research Lab, Stanford University.